


Homework 2

LCRS 星系样本分析报告

姜玥晟

2026-04-21



项目	内容
源题编号	HW02
学生姓名	姜玥晟
报告主题	LCRS 星系样本清洗、极值统计与三维可视化
实验环境	Python 数据处理与 matplotlib 三维绘图

I. LCRS 星系样本的清洗与极值统计

Problem 1: LCRS 星系样本的清洗与极值统计

题目给出 `lcrs.txt`。文件前部包含注释行，数据区的每条有效记录有四列，分别表示 recession velocity、球坐标角 `theta`、球坐标角 `phi` 以及红光波段 `absolute magnitude`。

1.1 Problem 1(a): 数据清洗与速度极值

相关脚本：

- 本地 `scripts/problem1.py`
- GitHub `scripts/problem1.py`

1.1.1 待求问题

去除注释行，保留纯数值记录，并求出 recession velocity 的最小值与最大值。

1.1.2 解决方式

统计流程可形式化表示为如下伪代码：

Input : raw catalog lines

Output: cleaned samples and extrema summary

```
samples <- []
for each line in catalog do
  fields <- split(line)
  if line is comment then
    continue
  end if
  if number_of(fields) != 4 then
    continue
  end if
  if first field is not numeric then
    continue
  end if
  append parsed record to samples
end for

v_min <- argmin recession_velocity in samples
v_max <- argmax recession_velocity in samples
m_bright <- argmin absolute_magnitude in samples
m_faint <- argmax absolute_magnitude in samples
write summary to galaxies.txt
```

上述流程由 `scripts/analyze_lcrs.py` 实现, 并通过 `results/galaxies.txt` 输出最终统计结果。

1.1.3 问题答案

清洗后得到 734 条有效记录。`recession velocity` 的最小值为 3734 km/s, 最大值为 78736 km/s。上述统计结果已经写入 `results/galaxies.txt`。

1.1.4 分析

该结果与 `flux-limited survey` 的观测选择效应相一致。由于观测系统只能记录亮度高于阈值的天体, 距离较远的星系若要进入样本, 就必须拥有更高的本征亮度; 反之, 本征较暗的星系通常只能在较近距离被探测到。本次统计中, 最亮星系对应的 `recession velocity` 远高于最暗星系, 这一现象正体现了上述选择效应。

从样本覆盖范围看, 最大与最小 `recession velocity` 之差达到 75002 km/s, 说明样本已经跨越较宽的距离尺度。因此, 极值对比并非局部波动, 而是样本筛选机制在全体观测中的直接反映。

1.2 Problem 1(b): 最亮与最暗星系

相关脚本:

- 本地 `scripts/problem1.py`
- GitHub `scripts/problem1.py`

1.2.1 待求问题

找出最亮星系与最暗星系对应的 `recession velocity`。

1.2.2 解决方式

统计流程可形式化表示为如下伪代码:

Input : raw catalog lines

Output: cleaned samples and extrema summary

```
samples <- []
for each line in catalog do
    fields <- split(line)
    if line is comment then
        continue
    end if
    if number_of(fields) != 4 then
        continue
    end if
    if first field is not numeric then
        continue
    end if
```

```

    append parsed record to samples
end for

v_min <- argmin recession_velocity in samples
v_max <- argmax recession_velocity in samples
m_bright <- argmin absolute_magnitude in samples
m_faint <- argmax absolute_magnitude in samples
write summary to galaxies.txt

```

上述流程由 `scripts/analyze_lcrs.py` 实现，并通过 `results/galaxies.txt` 输出最终统计结果。

1.2.3 问题答案

最亮星系的 `absolute magnitude` 为 `-22.7668247`，对应 `recession velocity` 为 `54610 km/s`；最暗星系的 `absolute magnitude` 为 `-17.581007`，对应 `recession velocity` 为 `3734 km/s`。

1.2.4 分析

该结果与 `flux-limited survey` 的观测选择效应相一致。由于观测系统只能记录亮度高于阈值的天体，距离较远的星系若要进入样本，就必须拥有更高的本征亮度；反之，本征较暗的星系通常只能在较近距离被探测到。本次统计中，最亮星系对应的 `recession velocity` 远高于最暗星系，这一现象正体现了上述选择效应。

从样本覆盖范围看，最大与最小 `recession velocity` 之差达到 `75002 km/s`，说明样本已经跨越较宽的距离尺度。因此，极值对比并非局部波动，而是样本筛选机制在全体观测中的直接反映。

1.3 Problem 1(c): 选择效应解释

相关脚本：

- 本地 `scripts/problem1.py`
- GitHub `scripts/problem1.py`

1.3.1 待求问题

结合该样本来自 `flux-limited survey` 的背景，对上述结果给出定性解释。

题目同时要求把计算结果写入 `galaxies.txt`。

1.3.2 解决方式

统计流程可形式化表示为如下伪代码：

```

Input : raw catalog lines
Output: cleaned samples and extrema summary

samples <- []
for each line in catalog do

```

```

fields <- split(line)
if line is comment then
  continue
end if
if number_of(fields) != 4 then
  continue
end if
if first field is not numeric then
  continue
end if
append parsed record to samples
end for

v_min <- argmin recession_velocity in samples
v_max <- argmax recession_velocity in samples
m_bright <- argmin absolute_magnitude in samples
m_faint <- argmax absolute_magnitude in samples
write summary to galaxies.txt

```

上述流程由 `scripts/analyze_lcrs.py` 实现，并通过 `results/galaxies.txt` 输出最终统计结果。

1.3.3 问题答案

最亮星系对应的 recession velocity 显著高于最暗星系，这与 flux-limited survey 的选择效应一致。距离较远的星系若要进入样本，必须具有更高的本征亮度；本征较暗的星系则往往只会在较近距离被观测到。

1.3.4 分析

该结果与 flux-limited survey 的观测选择效应相一致。由于观测系统只能记录亮度高于阈值的天体，距离较远的星系若要进入样本，就必须拥有更高的本征亮度；反之，本征较暗的星系通常只能在较近距离被探测到。本次统计中，最亮星系对应的 recession velocity 远高于最暗星系，这一现象正体现了上述选择效应。

从样本覆盖范围看，最大与最小 recession velocity 之差达到 75002 km/s，说明样本已经跨越较宽的距离尺度。因此，极值对比并非局部波动，而是样本筛选机制在全体观测中的直接反映。

II. LCRS 数据的三维可视化

Problem 2: LCRS 数据的三维可视化

题目要求把 LCRS 数据视为以太阳为原点的三维球坐标样本，并从不同视角观察其空间分布。

2.1 Problem 2(1): 三维坐标构造

相关脚本：

- 本地 `scripts/problem2.py`

- GitHub scripts/problem2.py

2.1.1 待求问题

已知第一列 recession velocity 作为径向距离，第二、三列分别提供方向信息，因此需要将球坐标样本转换为笛卡尔坐标。

2.1.2 解决方式

可视化流程如下：

Input : cleaned samples (v, theta, phi, magnitude)

Output: 3D overview and orthogonal views

```
for each sample do
  r <- v
  x <- r * sin(theta) * cos(phi)
  y <- r * sin(theta) * sin(phi)
  z <- r * cos(theta)
  map magnitude to marker color and marker size
end for
```

```
plot 3D scatter overview
plot XY projection
plot XZ projection
plot YZ projection
save figure to lcrrs_3d_views.png
```

其中颜色与点大小共同编码星系亮度，以便在空间位置之外同时保留亮度信息。

2.1.3 问题答案

将样本从球坐标转换为笛卡尔坐标后，已经生成三维总览图和三个正交投影视图，如图 1 所示。

2.1.4 分析

对这类三维星表数据而言，单张三维散点图常会受到遮挡影响，导致局部密集区域难以辨认。将 XY、XZ、YZ 三个投影视图与三维总览图并列展示，可以把不同方向的信息解耦，从而更稳定地观察样本的几何形态。

此外，三维图与第一题中的统计结果共享同一批清洗后的 734 条样本，因此统计结论与可视化结果之间具有统一的数据口径。这一点对于正式报告尤为重要，因为它保证了“结论”“图像”“原始结果文件”之间可以相互印证，而不是来自不同的数据子集。

2.2 Problem 2(2): 多视角可视化

相关脚本：




图 1: LCRS 数据的三维总览与三组投影视图

- 本地 scripts/problem2.py
- GitHub scripts/problem2.py

2.2.1 待求问题

在完成三维建模后，还需要从不同视角观察其空间分布。

2.2.2 解决方式

可视化流程如下：

Input : cleaned samples (v, theta, phi, magnitude)

Output: 3D overview and orthogonal views

```
for each sample do
  r <- v
  x <- r * sin(theta) * cos(phi)
  y <- r * sin(theta) * sin(phi)
  z <- r * cos(theta)
  map magnitude to marker color and marker size
end for
```

```
plot 3D scatter overview
plot XY projection
plot XZ projection
plot YZ projection
save figure to lcrs_3d_views.png
```

其中颜色与点大小共同编码星系亮度，以便在空间位置之外同时保留亮度信息。

2.2.3 问题答案

图 1 同时给出了三维总览和 XY、XZ、YZ 三个方向的投影，因此满足题目“从不同视角观察分布”的要求，能够同时呈现样本的整体空间形态和不同方向上的投影结构。

2.2.4 分析

对这类三维星表数据而言，单张三维散点图常会受到遮挡影响，导致局部密集区域难以辨认。将 XY、XZ、YZ 三个投影视图与三维总览图并列展示，可以把不同方向的信息解耦，从而更稳定地观察样本的几何形态。

此外，三维图与第一题中的统计结果共享同一批清洗后的 734 条样本，因此统计结论与可视化结果之间具有一致的数据口径。这一点对于正式报告尤为重要，因为它保证了“结论”“图像”“原始结果文件”之间可以相互印证，而不是来自不同的数据子集。