


Homework 4

数值稳定性分析报告

姜玥晟

2026-04-21



项目	内容
作业编号	HW04
作业目录	HW/03
学生姓名	姜玥晟
报告主题	二次方程求根稳定性、多项式求值稳定性与 half precision 舍入误差
实验环境	C 数值程序与 Python 统计绘图程序
报告说明	正文按题目编号组织，图表与实验统计对应同一批运行结果，完整实现保留于 scripts/。

1 二次方程小根的相消误差分析

1.1 题目陈述

考察二次方程

$$x^2 - bx + 1 = 0,$$

其两根可写为

$$x_1 = \frac{b+r}{2}, \quad x_2 = \frac{b-r}{2}, \quad r = \sqrt{b^2 - 4}.$$

当 b 足够大时, r 与 b 的数值非常接近, 小根

$$x_2 = \frac{b-r}{2}$$

的计算将涉及两个接近量之间的相减。

1.1.1 (1) $b=100$ 附近的误差考察

首先考察该表达式在 $b=100$ 附近的相对误差。

1.1.2 (2) 大参数区间的误差比较

随后增大 b 取值并列表比较误差变化。

1.1.3 (3) 有理化改写与再实验

最后将小根公式改写为

$$x_2 = \frac{(b-r)(b+r)}{2(b+r)} = \frac{2}{b+r},$$

并重新进行同样的实验, 以比较两种实现的稳定性差异。

1.2 解决方案

为使实验步骤表达得更规范, 本文以伪代码方式给出求解过程:

Input : precisions P , test values B

Output: error table and error curve

for each p in P do

 for each b in B do

```

        r <- sqrt(b^2 - 4)
        x_std <- (b - r) / 2
        x_rat <- 2 / (b + r)
        x_ref <- ref_root(b)
        err_std <- relerr(x_std, x_ref)
        err_rat <- relerr(x_rat, x_ref)
    end for
end for

```

其中 `ref_root(b)` 表示高精度参考解，`relerr` 表示相对误差计算函数。

1.3 问题答案

1.3.1 (1) $b=100$ 附近的误差考察

依据题图第二页给出的三位有效数字示例，取 $b=97$ 时有

$$x_2^{\text{exact}} = 0.01031, \quad x_2^{\text{standard}} = 0.01050,$$

相应相对误差为 $1.8429\text{E-}2$ ，约为 1.84% 。然而，在本机 IEEE float 运算中， $b=100$ 的标准公式相对误差仅为 $1.1359\text{E-}4$ 。这表明题图中“about 2%”的表述对应的是低精度教学示例，而非标准单精度在 $b=100$ 时的实际结果。

1.3.2 (2) 大参数区间的误差比较

当 b 继续增大时，标准公式的误差迅速放大，而有理化公式保持稳定。误差变化趋势如图所示。

表 1 给出了代表性结果。

精度	b	标准误差	有理化误差	改进倍数
float	100	1.1359E-4	2.0003E-8	5.6786E+3
float	1000	7.0791E-3	2.0002E-8	3.5392E+5
float	10000	1.0000E+0	3.5000E-8	2.8571E+7
double	100000	3.3844E-7	9.9980E-17	3.3850E+9
double	10000000000	1.0000E+0	1.0000E-20	1.0000E+20
quad	100000000000	6.8266E-16	1.0000E-34	6.8266E+18

对于 float，当 $b=10000$ 时，标准公式的相对误差已达到 $1.0000\text{E+}0$ ，说明小根信息几乎完全丢失；对应的有理化误差仍只有 $3.5000\text{E-}8$ 。对于 double，在 $b=10^9$ 时也出现同类退化，而 `__float128` 在同一测试点仍维持 $6.8266\text{E-}16$ 的误差量级。

1.3.3 (3) 有理化改写与再实验

有理化后未再出现与标准公式同量级的误差爆炸。实验范围内，有理化公式始终显著优于标准公式；例如在 double， $b=10^9$ 条件下，标准公式误差为 $1.0000\text{E+}0$ ，而有理化公式误差为 $1.0000\text{E-}20$ 。

Problem 1: Relative Error of the Small Root




图 1: Problem 1 relative-error comparison

1.4 讨论和扩展

标准公式的不稳定性来源于相消误差。由近似关系

$$\sqrt{b^2 - 4} = b\sqrt{1 - 4/b^2} \approx b - \frac{2}{b}$$

可知, 当 b 很大时, 表达式

$$b - \sqrt{b^2 - 4}$$

仅保留数量级约为 $2/b$ 的小量, 高位有效数字会在减法阶段被提前消耗。有理化公式

$$x_2 = \frac{2}{b + \sqrt{b^2 - 4}}$$

将这一相减过程替换为除法运算, 因此显著抑制了误差放大。进一步地, 由根的乘积关系 $x_1 x_2 = 1$ 还可得到另一种稳定实现, 即先稳定计算较大的根 x_1 , 再由 $x_2 = 1/x_1$ 得到小根。

2 多项式写法对数值稳定性的影响

2.1 题目陈述

作业要求在 `single`、`double` 与 `quad` 三种精度下计算

$$(x - 1)^{10}$$

及其多项式展开式, 并在区间 $x \in [0.7, 1.3]$ 上观察数值结果。

2.1.1 (1) 局部放大观察

比较直接形式与展开形式在局部区间上的数值表现。

2.1.2 (2) 相对误差分布

绘制并比较误差分布。

2.1.3 (3) Horner 方法比较

再使用 Horner 方法重新组织多项式计算, 比较三种实现的误差分布, 并解释在 $x = 1$ 邻域出现差异的原因。

2.2 解决方案

本题的实验组织可形式化表示为：

Input : grid X , methods M , precisions P

Output: zoomed plots and error statistics

```
for each p in P do
  for each x in X do
    y_ref <- high_precision((x - 1)^10)
    for each m in M do
      y <- eval(m, x, p)
      if y_ref != 0 then
        err[m, x, p] <- relerr(y, y_ref)
      end if
    end for
  end for
end for
```

其中 $M = \{\text{direct}, \text{expanded}, \text{horner}\}$ ，并基于 err 进一步统计最大误差、峰值位置与中位误差。

2.3 问题答案

2.3.1 (1) 局部放大观察

局部放大结果表明，直接形式在三个精度下均最接近参考曲线，而展开形式与 Horner 形式在 $x = 1$ 附近出现明显偏离。

造成该现象的直接原因在于：当 x 接近 1 时，真值 $(x - 1)^{10}$ 极小；若先将多项式展开为多个数量级接近的项再相加减，就会显著放大舍入误差。

2.3.2 (2) 相对误差分布

相对误差统计结果如下。

精度	形式	最大相对误差	峰值位置 x	中位相对误差
float	direct	7.5107E-5	1.0005	9.5128E-8
float	expanded	1.7450E+31	0.99975002	1.3713E+3
float	horner	4.9415E+30	1.00025	7.3785E+2
double	direct	8.9867E-13	1.0005	5.2885E-16
double	expanded	2.6543E+22	1.00025	2.4256E-6
double	horner	1.4552E+22	1.00025	1.4286E-6
quad	direct	1.8490E-31	1.00025	1.2808E-34
quad	expanded	1.2522E+4	0.99975	2.3220E-24
quad	horner	9.3896E+3	0.99975	1.3699E-24

Problem 2: Zoomed Values on x in [0.7, 1.3]




图 2: Problem 2 zoomed-value comparison




图 3: Problem 2 relative-error distribution

其中最显著的退化出现在 `float + expanded` 组合，其最大相对误差达到 $1.7450\text{E}+31$ ，峰值出现在 $x=0.99975002$ 附近；相比之下，同为 `float` 的直接形式最大相对误差仅为 $7.5107\text{E}-5$ 。即使在 `quad` 精度下，展开形式的最大相对误差仍达到 $1.2522\text{E}+4$ ，说明表达式结构对稳定性的影响并不会因精度提升而完全消失。

2.3.3 (3) Horner 方法比较

Horner 方法明显优于朴素展开形式，但仍劣于直接形式。以 `float` 为例，Horner 形式的最大相对误差为 $4.9415\text{E}+30$ ，相较朴素展开已有改善，但仍远大于直接形式。这说明 Horner 方法虽然减少了重复幂与大规模加减运算，却没有保留原问题中最关键的小量结构 $(x - 1)$ 。

2.4 讨论和扩展

本题显示出“问题条件数”与“算法稳定性”之间的区别。在 $x = 1$ 附近，真值本身非常接近零，因此任何微小的绝对误差都可能被转换为极大的相对误差。直接形式由于始终保留 $(x - 1)$ 这一小量结构，运算路径最短，因而最稳定；朴素展开形式则会反复累积和抵消数量级接近的项，最容易触发相消误差；Horner 形式虽然改善了运算顺序，但并未改变展开后计算的本质。若需进一步提高稳定性，可结合高精度算术、补偿求和或围绕 $x = 1$ 的局部重参数化方案。

3 Half Precision 的机器精度与舍入误差

3.1 题目陈述

作业要求完成以下两项工作：

3.1.1 (1) 基本指标测量

给出 half precision (binary16) 的 machine precision、数值范围等基本指标。

3.1.2 (2) 舍入误差算例

构造一个具体算例，说明在半精度环境下 roundoff error 可以严重到何种程度。

3.2 解决方案

本题采用的实验步骤可归纳为如下伪代码：

Input : half type h, parameter set T

Output: metric table and roundoff plot

```
probe epsilon(h), min_normal(h)
probe true_min(h), max_finite(h)

for each t in T do
  y_dir <- ((1 + t)^2 - 1) / t
  y_alt <- 2 + t
  y_ref <- high_precision(2 + t)
  if y_ref != 0 then
    err_dir <- relerr(y_dir, y_ref)
    err_alt <- relerr(y_alt, y_ref)
  end if
end for
```

通过比较 y_{dir} 与 y_{alt} 的误差变化，可直接观察 half precision 下的舍入误差放大现象。

3.3 问题答案

3.3.1 (1) 基本指标测量

_Float16 的主要数值指标如表所示。

指标	数值
_Float16 size	2 bytes
bit pattern of 1.0	0x3c00
machine epsilon	0.0009765625
min normal	6.103515625e-05
true min	5.9604644775390625e-08
max finite	65504

上述结果与 binary16 的 1 位符号位、5 位指数位和 10 位尾数位结构一致，说明实验环境中的 half precision 实现符合常见 IEEE 754 binary16 格式。

3.3.2 (2) 舍入误差算例

为说明舍入误差的严重程度，选取表达式

$$\frac{(1+t)^2 - 1}{t},$$

其精确值为 $2+t$ 。当 $t=0.00048828125$ 时，半精度直接计算结果已退化为 0，而精确值仍为 2.00048828125 ；此时相对误差达到 $1.0000E+0$ 。若改写为 $2+t$ ，同一点的相对误差仅为 $2.4408E-4$ 。

Problem 3: Roundoff Error in Half Precision




图 4: Problem 3 roundoff comparison in half precision

3.3.3 (3) 误差严重程度结论

因此，half precision 的 machine epsilon 约为 $2^{(-10)}$ ，有效数字极为有限；一旦表达式包含相消运算，舍入误差完全可能将本应处于 2 量级的结果直接压缩为 0。

3.4 讨论和扩展

half precision 在 1 附近的间隔约为 $2^{(-10)}$ 。当 t 小于或接近这一阈值时， $1+t$ 将首先被舍入回 1，进而使 $(1+t)^2 - 1$ 被舍入为 0。本题中的首个失真点正好出现在 $t=0.00048828125$ ，即 machine epsilon 的一半附近，这与 binary16 的舍入行为相一致。由此可见，在低精度格式中，算法结构往往比“理论等价”更重要；对含有相消项的表达式进行代数改写，是避免灾难性误差的关键手段。