

Homework 4

数值稳定性分析报告

姜玥晟

2026-04-21



项目	内容
源题编号	HW04
学生姓名	姜玥晟
报告主题	二次方程求根稳定性、多项式求值稳定性与 half precision 舍入误差
实验环境	C 数值程序与 Python 统计绘图程序

目录

I. 二次方程小根的相消误差分析	3
II. 多项式写法对数值稳定性的影响	8
III. Half Precision 的机器精度与舍入误差	14

I. 二次方程小根的相消误差分析

Problem 1: 二次方程小根的相消误差分析

考察二次方程

$$x^2 - bx + 1 = 0,$$

其两根可写为

$$x_1 = \frac{b+r}{2}, \quad x_2 = \frac{b-r}{2}, \quad r = \sqrt{b^2 - 4}.$$

当 b 足够大时, r 与 b 的数值非常接近, 小根

$$x_2 = \frac{b-r}{2}$$

的计算将涉及两个接近量之间的相减。

1.1 Problem 1(1): $b = 100$ 附近的误差考察

相关脚本:

- 本地 scripts/problem1.c
- GitHub scripts/problem1.c

1.1.1 待求问题

首先考察该表达式在 $b=100$ 附近的相对误差。

1.1.2 解决方式

为使实验步骤表达得更规范, 本文以伪代码方式给出求解过程:

Input : precisions P , $b = 100$

Output: standard-form error at $b = 100$

```
for each p in P do
  r <- sqrt(b^2 - 4)
  x_std <- (b - r) / 2
  x_ref <- ref_root(b)
  err_std <- relerr(x_std, x_ref)
end for
```

其中 $\text{ref_root}(b)$ 表示高精度参考解, relerr 表示相对误差计算函数。

1.1.3 答案

对于题目指定的 $b=100$ ，本机 IEEE float 运算给出

$$x_2^{\text{standard}} = 0.0100021362,$$

高精度参考值约为 0.010001000200050014。标准公式相对误差为 1.1359E-4。

题图第二页另给出 $b=97$ 的三位有效数字教学示例：

$$x_2^{\text{exact}} = 0.01031, \quad x_2^{\text{standard}} = 0.01050,$$

该示例的相对误差为 1.8429E-2，约为 1.84%，用于说明低精度三位有效数字运算中的相消误差；它不是 $b=100$ 的主计算结果。

标准公式的不稳定性来源于相消误差。由近似关系

$$\sqrt{b^2 - 4} = b\sqrt{1 - 4/b^2} \approx b - \frac{2}{b}$$

可知，当 b 很大时，表达式

$$b - \sqrt{b^2 - 4}$$

仅保留数量级约为 $2/b$ 的小量，高位有效数字会在减法阶段被提前消耗。因此，本问只能说明标准公式已经出现相消误差；如何通过代数改写避开该相减过程，留到 Problem 1(3) 再处理。

1.2 Problem 1(2)：大参数区间的误差比较

相关脚本：

- 本地 scripts/problem1.c
- GitHub scripts/problem1.c

1.2.1 待求问题

随后增大 b 取值并列表比较误差变化。

1.2.2 解决方式

为使实验步骤表达得更规范，本文以伪代码方式给出求解过程：

Input : precisions P, test values B

Output: standard-form error table

for each p in P do

```

    for each b in B do
        r <- sqrt(b^2 - 4)
        x_std <- (b - r) / 2
        x_ref <- ref_root(b)
        err_std <- relerr(x_std, x_ref)
    end for
end for

```

其中 `ref_root(b)` 表示高精度参考解，`relerr` 表示相对误差计算函数。

1.2.3 答案

继续增大 b 并仍然只使用标准公式 $x_2 = (b - r)/2$ 时，代表性相对误差如下。

精度	b	标准公式相对误差
float	100	1.1359E-4
float	1000	7.0791E-3
float	10000	1.0000E+0
double	100000	3.3844E-7
double	10000000000	1.0000E+0
quad	10000000000	6.8266E-16

对于 `float`，当 $b=10000$ 时，标准公式的相对误差已达到 $1.0000E+0$ ，说明小根信息几乎完全丢失。对于 `double`，在 $b=10^{10}$ 时也出现同类退化，而 `__float128` 在同一测试点仍维持 $6.8266E-16$ 的误差量级。

标准公式的不稳定性来源于相消误差。由近似关系

$$\sqrt{b^2 - 4} = b\sqrt{1 - 4/b^2} \approx b - \frac{2}{b}$$

可知，当 b 很大时，表达式

$$b - \sqrt{b^2 - 4}$$

仅保留数量级约为 $2/b$ 的小量，高位有效数字会在减法阶段被提前消耗。表中的退化正是这一相消过程随 b 增大而加剧的结果。下一问再对这个表达式进行代数改写，并用同一组 b 值复现实验。

1.3 Problem 1(3)：有理化改写与再实验

相关脚本：

- 本地 `scripts/problem1.c`
- GitHub `scripts/problem1.c`

1.3.1 待求问题

最后将小根公式改写为

$$x_2 = \frac{(b-r)(b+r)}{2(b+r)} = \frac{2}{b+r},$$

并重新进行同样的实验，以比较两种实现的稳定性差异。

1.3.2 解决方式

为使实验步骤表达得更规范，本文以伪代码方式给出求解过程：

Input : precisions P, test values B

Output: error table and error curve

```
for each p in P do
  for each b in B do
    r <- sqrt(b^2 - 4)
    x_std <- (b - r) / 2
    x_rat <- 2 / (b + r)
    x_ref <- ref_root(b)
    err_std <- relerr(x_std, x_ref)
    err_rat <- relerr(x_rat, x_ref)
  end for
end for
```

其中 `ref_root(b)` 表示高精度参考解，`relerr` 表示相对误差计算函数。

1.3.3 答案

对同一组 b 值重新实验后，代表性结果如下。

Problem 1: Relative Error of the Small Root




图 1: Problem 1 relative-error comparison after rationalization

精度	b	标准公式相对误差	有理化公式相对误差	改进倍数
float	100	1.1359E-4	2.0003E-8	5.6786E+3
float	1000	7.0791E-3	2.0002E-8	3.5392E+5
float	10000	1.0000E+0	3.5000E-8	2.8571E+7
double	100000	3.3844E-7	9.9980E-17	3.3850E+9
double	10000000000	1.0000E+0	1.0000E-20	1.0000E+20

精度	b	标准公式相对误差	有理化公式相对误差	改进倍数
quad	10000000000	6.8266E-16	1.0000E-34	6.8266E+18

这些数据说明, 有理化后未再出现与标准公式同量级的误差爆炸。实验范围内, 有理化公式始终显著优于标准公式; 例如在 `double` 且 $b = 10^{10}$ 条件下, 标准公式误差为 1.0000E+0, 而有理化公式误差为 1.0000E-20。标准公式的不稳定性来源于相消误差。由近似关系

$$\sqrt{b^2 - 4} = b\sqrt{1 - 4/b^2} \approx b - \frac{2}{b}$$

可知, 当 b 很大时, 表达式

$$b - \sqrt{b^2 - 4}$$

仅保留数量级约为 $2/b$ 的小量, 高位有效数字会在减法阶段被提前消耗。有理化公式

$$x_2 = \frac{2}{b + \sqrt{b^2 - 4}}$$

将这一相减过程替换为除法运算, 因此显著抑制了误差放大。进一步地, 由根的乘积关系 $x_1 x_2 = 1$ 还可得到另一种稳定实现, 即先稳定计算较大的根 x_1 , 再由 $x_2 = 1/x_1$ 得到小根。

II. 多项式写法对数值稳定性的影响

Problem 2: 多项式写法对数值稳定性的影响

作业要求在 `single`、`double` 与 `quad` 三种精度下计算

$$(x - 1)^{10}$$

及其多项式展开式, 并在区间 $x \in [0.7, 1.3]$ 上观察数值结果。

2.1 Problem 2(1): 局部放大观察

相关脚本:

- 本地 `scripts/problem2.c`
- GitHub `scripts/problem2.c`

2.1.1 待求问题

比较直接形式与展开形式在局部区间上的数值表现。

2.1.2 解决方式

本题的实验组织可形式化表示为:

Input : grid X , methods M , precisions P

Output: zoomed plots and error statistics

```
for each p in P do
  for each x in X do
    y_ref <- high_precision((x - 1)^10)
    for each m in M do
      y <- eval(m, x, p)
      if y_ref != 0 then
        err[m, x, p] <- relerr(y, y_ref)
      end if
    end for
  end for
end for
```

其中 $M = \{\text{direct}, \text{expanded}, \text{horner}\}$, 并基于 `err` 进一步统计最大误差、峰值位置与中位误差。

2.1.3 答案

局部放大结果表明, 直接形式在三个精度下均最接近参考曲线, 而展开形式与 Horner 形式在 $x = 1$ 附近出现明显偏离。

Problem 2: Zoomed Values on x in [0.7, 1.3]




图 2: Problem 2 zoomed-value comparison

造成该现象的直接原因在于：当 x 接近 1 时，真值 $(x - 1)^{10}$ 极小；若先将多项式展开为多个数量级接近的项再相加减，就会显著放大舍入误差。

本小问关注的是局部曲线形状。直接形式先计算 $u = x - 1$ ，再计算 u^{10} ，整个过程中被反复相乘的是接近零的小量；因此它能保留函数在 $x = 1$ 附近的平滑谷底。展开式则把同一个函数写成

$$x^{10} - 10x^9 + 45x^8 - \dots - 10x + 1,$$

在 $x \approx 1$ 时，上式各项本身仍是 $O(1)$ 量级，最后却要抵消成 $O(|x - 1|^{10})$ 的极小结果。局部放大图中展开式曲线偏离参考曲线，说明问题不在函数本身，而在表达式写法引入了大数相减。

2.2 Problem 2(2): 相对误差分布

相关脚本:

- 本地 scripts/problem2.c
- GitHub scripts/problem2.c

2.2.1 待求问题

绘制并比较误差分布。

2.2.2 解决方式

本题的实验组织可形式化表示为:

Input : grid X , methods M , precisions P

Output: zoomed plots and error statistics

```
for each p in P do
  for each x in X do
    y_ref <- high_precision((x - 1)^10)
    for each m in M do
      y <- eval(m, x, p)
      if y_ref != 0 then
        err[m, x, p] <- relerr(y, y_ref)
      end if
    end for
  end for
end for
```

其中 $M = \{\text{direct}, \text{expanded}, \text{horner}\}$, 并基于 err 进一步统计最大误差、峰值位置与中位误差。

2.2.3 答案

相对误差统计结果如下。图中使用离散采样点而非折线连接; 靠近 $x = 1$ 的针状峰来自相对误差分母 $|(x - 1)^{10}|$ 极小, 少量绝对舍入误差被放大。相邻采样点误差可差多个数量级, 若用折线连接会产生视觉上的竖直突变线, 因此这里展示采样分布而不把它解释成连续曲线突变。

Problem 2: Relative-Error Distribution




图 3: Problem 2 relative-error distribution

精度	形式	最大相对误差	峰值位置 x	中位相对误差
float	direct	7.5107E-5	1.0005	9.5128E-8
float	expanded	1.7450E+31	0.99975002	1.3713E+3
float	horner	4.9415E+30	1.00025	7.3785E+2
double	direct	8.9867E-13	1.0005	5.2885E-16
double	expanded	2.6543E+22	1.00025	2.4256E-6
double	horner	1.4552E+22	1.00025	1.4286E-6
quad	direct	1.8490E-31	1.00025	1.2808E-34

精度	形式	最大相对误差	峰值位置 x	中位相对误差
quad	expanded	1.2522E+4	0.99975	2.3220E-24
quad	horner	9.3896E+3	0.99975	1.3699E-24

其中最显著的退化出现在 `float + expanded` 组合，其最大相对误差达到 $1.7450\text{E}+31$ ，峰值出现在 $x=0.99975002$ 附近；相比之下，同为 `float` 的直接形式最大相对误差仅为 $7.5107\text{E}-5$ 。即使在 `quad` 精度下，展开形式的最大相对误差仍达到 $1.2522\text{E}+4$ ，说明表达式结构对稳定性的影响并不会因精度提升而完全消失。

本小问关注的是相对误差的分布，而不是函数值本身。相对误差按

$$\text{relerr}(x) = \frac{|y(x) - y_{\text{ref}}(x)|}{|y_{\text{ref}}(x)|}$$

计算；当 x 靠近 1 时，参考值 $y_{\text{ref}} = (x - 1)^{10}$ 极小，所以即使绝对误差只有 10^{-14} 或 10^{-6} ，也会被分母放大到很高的相对误差。统计表中的峰值位置均集中在 $x = 1$ 附近，例如 `float + expanded` 的峰值在 $x=0.99975002$ ，最大相对误差达到 $1.7450\text{E}+31$ 。图中的针状峰因此是相对误差定义和采样点共同造成的结果，不应理解为原函数出现了真实间断。

2.3 Problem 2(3): Horner 方法比较

相关脚本：

- 本地 `scripts/problem2.c`
- GitHub `scripts/problem2.c`

2.3.1 待求问题

再使用 Horner 方法重新组织多项式计算，比较三种实现的误差分布，并解释在 $x = 1$ 邻域出现差异的原因。

2.3.2 解决方式

本题的实验组织可形式化表示为：

Input : grid X , methods M , precisions P
Output: zoomed plots and error statistics

```
for each p in P do
  for each x in X do
    y_ref <- high_precision((x - 1)^10)
    for each m in M do
      y <- eval(m, x, p)
      if y_ref != 0 then
```

```

        err[m, x, p] <- relerr(y, y_ref)
      end if
    end for
  end for
end for

```

其中 $M = \{\text{direct}, \text{expanded}, \text{horner}\}$ ，并基于 `err` 进一步统计最大误差、峰值位置与中位误差。

2.3.3 答案

Horner 方法的独立对比结果如下。表中“最大误差改善倍数”和“中位误差改善倍数”均定义为 `expanded` 误差除以 `horner` 误差；数值大于 1 表示 Horner 优于朴素展开。

精度	direct 最大相对误差	expanded 最大相对误差	horner 最大相对误差	最大误差改善倍数	中位误差改善倍数
float	7.5107E-5	1.7450E+31	4.9415E+30	3.5314E+0	1.8585E+0
double	8.9867E-13	2.6543E+22	1.4552E+22	1.8240E+0	1.6979E+0
quad	1.8490E-31	1.2522E+4	9.3896E+3	1.3336E+0	1.6949E+0

结果表明，Horner 方法在三种精度下都比朴素展开稳定；以 `float` 为例，最大相对误差从 $1.7450E+31$ 降到 $4.9415E+30$ ，改善约 3.5314 倍。但它仍显著劣于直接形式：同一精度下 `direct` 的最大相对误差只有 $7.5107E-5$ 。结论是 Horner 改善了展开式的运算顺序，但没有恢复直接形式保留的关键小量结构 $(x - 1)$ 。

本小问关注 Horner 方法的作用边界。Horner 写法减少了显式幂次计算和中间加减次数，所以相对朴素展开有稳定性收益；表中三种精度的最大误差改善倍数分别为 $3.5314E+0$ 、 $1.8240E+0$ 和 $1.3336E+0$ 。不过 Horner 仍是在计算展开后的同一个多项式，无法消除 $x \approx 1$ 时多个 $O(1)$ 项抵消成极小量的结构性问题。因此它优于朴素展开，但与直接形式相比仍不是同一稳定性等级。真正稳定的策略是保留因式分解形式 $(x - 1)^{10}$ ，或在必须使用展开式时再引入补偿求和、局部重参数化等额外手段。

III. Half Precision 的机器精度与舍入误差

Problem 3: Half Precision 的机器精度与舍入误差

作业要求完成以下两项工作：

3.1 Problem 3(1)：基本指标测量

相关脚本：

- 本地 `scripts/problem3.c`
- GitHub `scripts/problem3.c`

3.1.1 待求问题

给出 half precision (binary16) 的 machine precision、数值范围等基本指标。

3.1.2 解决方式

本题采用的实验步骤可归纳为如下伪代码：

Input : half type h, parameter set T

Output: metric table and roundoff plot

```
probe epsilon(h), min_normal(h)
probe true_min(h), max_finite(h)

for each t in T do
  y_dir <- ((1 + t)^2 - 1) / t
  y_alt <- 2 + t
  y_ref <- high_precision(2 + t)
  if y_ref != 0 then
    err_dir <- relerr(y_dir, y_ref)
    err_alt <- relerr(y_alt, y_ref)
  end if
end for
```

通过比较 y_{dir} 与 y_{alt} 的误差变化，可直接观察 half precision 下的舍入误差放大现象。

3.1.3 答案

_Float16 的主要数值指标如表所示。

指标	数值
_Float16 size	2 bytes
bit pattern of 1.0	0x3c00
machine epsilon	0.0009765625
min normal	6.103515625e-05
true min	5.9604644775390625e-08
max finite	65504

上述结果与 binary16 的 1 位符号位、5 位指数位和 10 位尾数位结构一致，说明实验环境中的 half precision 实现符合常见 IEEE 754 binary16 格式。

half precision 在 1 附近的间隔约为 2^{-10} 。当 t 小于或接近这一阈值时， $1+t$ 将首先被舍入回 1，进而使 $(1+t)^2-1$ 被舍入为 0。本题中的首个失真点正好出现在 $t=0.00048828125$ ，即 machine epsilon 的一半附近，这与 binary16 的舍入行为相一致。由此可见，在低精度格式中，算法结构往往比“理论等价”更重要；对含有相消项的表达式进行代数改写，是避免灾难性误差的关键手段。

3.2 Problem 3(2)：舍入误差算例

相关脚本：

- 本地 scripts/problem3.c
- GitHub scripts/problem3.c

3.2.1 待求问题

构造一个具体算例，说明在半精度环境下 roundoff error 可以严重到何种程度。

3.2.2 解决方式

本题采用的实验步骤可归纳为如下伪代码：

Input : half type h, parameter set T

Output: metric table and roundoff plot

```

probe epsilon(h), min_normal(h)
probe true_min(h), max_finite(h)

for each t in T do
  y_dir <- ((1 + t)^2 - 1) / t
  y_alt <- 2 + t
  y_ref <- high_precision(2 + t)
  if y_ref != 0 then
    err_dir <- relerr(y_dir, y_ref)
    err_alt <- relerr(y_alt, y_ref)
  end if
end for

```

通过比较 y_{dir} 与 y_{alt} 的误差变化，可直接观察 half precision 下的舍入误差放大现象。

3.2.3 答案

为说明舍入误差的严重程度，选取表达式

$$\frac{(1+t)^2 - 1}{t},$$

其精确值为 $2+t$ 。当 $t=0.00048828125$ 时，半精度直接计算结果已退化为 0，而精确值仍为 2.00048828125；此时相对误差达到 1.0000E+0。若改写为 $2+t$ ，同一点的相对误差仅为 2.4408E-4。

图中的跃变来自 half precision 的离散舍入阈值。 $2+t$ 在 $t \leq 2^{-10}$ 时会被舍入到 2；直接表达式更敏感，因为 $1+t$ 在 $t \leq 2^{-11}$ 时会先被舍入到 1，随后 $(1+t)^2 - 1$ 直接变为 0。

Problem 3: Roundoff Error in Half Precision




图 4: Problem 3 roundoff comparison in half precision

half precision 在 1 附近的相邻间隔为 2^{-10} ，最近舍入的半间隔为 2^{-11} 。因此当 $t = 2^{-11} = 0.00048828125$ 时， $1 + t$ 处在舍入边界并被舍入回 1，进而使 $(1 + t)^2 - 1$ 变为 0，直接表达式的相对误差跃升到 $1.0000\text{E}+0$ 。另一方面，2 附近的 half 间隔是 2^{-9} ，其半间隔是 2^{-10} ；所以 $2 + t$ 的改写形式在 $t = 2^{-10}$ 开始被量化为 2，相对误差也会出现台阶。由此可见，图中的跃变是浮点量化阈值造成的确定性现象，不是随机噪声或绘图错误。

3.3 Problem 3(3): 误差严重程度结论

相关脚本：

- 本地 scripts/problem3.c
- GitHub scripts/problem3.c

3.3.1 待求问题

总结 half precision 的 machine epsilon 与舍入误差算例，说明半精度环境下 roundoff error 可达到的严重程度。

3.3.2 答案

由前两问可直接得到结论：本机半精度的机器精度为 $2^{-10} = 0.0009765625$ 。在算例

$$\frac{(1+t)^2 - 1}{t}$$

中，当 $t = 2^{-11} = 0.00048828125$ 时，半精度直接计算结果为 0，而精确值仍为 2.00048828125，相对误差达到 1.0000E+0。也就是说，half precision 下的 roundoff error 可以严重到把本应为 2 量级的结果直接压成 0。

该结论直接由 Problem 3(1) 和 Problem 3(2) 的结果归纳得到。核心事实是 half precision 在 1 附近只有约 2^{-10} 的相邻分辨率，因此 $1+t$ 对小扰动并不连续响应；当 t 落到半间隔 2^{-11} 附近时，直接表达式会先把 $1+t$ 舍入回 1，再把整个分子压成 0。改写为 $2+t$ 后仍有 half 量化误差，但不会把结果从 2 量级直接压到 0。