

Homework 12

随机数生成器统计检验与接受-拒绝法实验报告

姜玥晟、周鑫志、高西飞

2026-05-20



姜玥晟



周鑫志



高西飞

项目	内容
源题编号	HW12
作业属性	小组作业
小组成员	姜玥晟、周鑫志、高西飞
报告主题	随机数生成器统计检验、准随机序列与接受-拒绝法估计 π
实验环境	Python 3.13.5、numpy 2.3.3、scipy、matplotlib、pypandoc

I. 随机数生成器统计检验

1 Problem 1: 卡方随机性检验

1.1 待求问题

对若干内置或自选随机数生成器做随机性的卡方检验。将单位立方体分成 N 个箱子，抽取许多 P 个三元组。若生成器给出的点在三维单位立方体内足够均匀且近似独立，则每个箱子的点数应接近

$$n = \frac{P}{N},$$

典型随机波动约为

$$\sqrt{\frac{P}{N}}.$$

题图给出的示例为 $N = 100$, $P = 1000$ 。

1.2 解决方式

本文统一将三维单位立方体 $[0, 1)^3$ 沿每个坐标方向分成 5 份，因此总箱数为

$$N_{\text{bin}} = 5^3 = 125.$$

每次检验抽取

$$P = 10000$$

个三元组，理论期望频数为

$$E = \frac{P}{N_{\text{bin}}} = 80.$$

对观测频数 O_i 计算卡方统计量

$$\chi^2 = \sum_{i=1}^{N_{\text{bin}}} \frac{(O_i - E)^2}{E}.$$

若样本近似来自独立均匀分布，则 χ^2 应近似服从自由度

$$\nu = N_{\text{bin}} - 1 = 124$$

的卡方分布。右尾 p 值过小表示分箱偏离过大；中心 p 值过小表示统计量落在卡方分布两端，既包括“过于不均匀”，也包括“过于均匀”。

线性同余生成器的递推式为

$$x_{k+1} = (ax_k + c) \bmod m, \quad u_k = \frac{x_k}{m}.$$

检验流程如下：

```
for each generator:
    repeat the chi-square experiment for many independent seeds
    generate P triples in  $[0, 1)^3$ 
    assign each triple to one of  $5^3$  bins
    compute chi-square statistic and p-values
    summarize representative run and repeated-run distribution

compare each generator with the chi-square distribution of  $df = 124$ 
```

1.3 问题答案

表 1 给出单次代表性检验和 200 次重复检验的汇总。自由度 124 的 0.5% 与 99.5% 分位数分别为 87.192079 和 168.308113；一个普通随机生成器的卡方值应大致落在该区间附近。

生成器	示例 χ^2	右尾 p 值	中心 p 值	最小/最大箱频数	200 次 χ^2 均值	中心 p 值通过率
numpy_pcg64	97.550	0.961914	0.076173	58 / 101	124.787	1.000
lcg_minstd	117.125	0.656288	0.687423	53 / 101	124.447	0.995
lcg_slide_large	4307.350	0	0	0 / 966	50540.683	0
lcg_slide_small	13046.875	0	0	0 / 375	20720.703	0
lcg_bad27	615000.000	0	0	0 / 5000	780625.000	0
lcg_bad9	406666.675	0	0	0 / 3334	406666.675	0

图 1 中，numpy_pcg64 和 lcg_minstd 的重复检验分布与理论卡方分布相当接近，而另外四组 LCG 的统计量远离理论范围。图 2 显示了单次检验中部分生成器的 125 个箱子频数。numpy_pcg64 和 lcg_minstd 的箱频数围绕 80 波动；坏 LCG 会产生大量空箱和少数极高频箱，说明三维点严重集中在某些结构上。

1.4 分析

本题说明，随机数生成器不应只看周期或参数规模。即使 $m = 2^{31} - 1$ 很大，若 a 和 c 选择不当，三维相邻样本仍可能落在很少的结构上，从而被卡方检验显著拒绝。相反，Park-Miller 型 LCG 在本实验的三维分箱尺度上表现接近内置 PCG64。

卡方检验本身也有局限。它只检验所选分箱下的均匀性，不能证明生成器在所有维度、所有变换下都随机。因此，实际评价生成器时还需要结合高维谱检验、自相关检验、运行检验等更丰富的统计测试。




图 1: 卡方统计量重复检验分布




图 2: 单次三维分箱频数示例

2 Problem 2: 样本均值的最小统计检验

2.1 待求问题

使用一个最小统计检验判断随机数生成器的样本均值是否接近 0.5，并测试内置随机数生成器和自己写的生成器。

2.2 解决方式

若 u_i 独立服从 $U(0, 1)$ ，则

$$\mathbb{E}(u_i) = \frac{1}{2}, \quad \text{Var}(u_i) = \frac{1}{12}.$$

对 M 个样本的均值 $\bar{u}$ ，中心极限定理给出

$$\bar{u} \approx N\left(\frac{1}{2}, \frac{1}{12M}\right).$$

因此可构造

$$z = \frac{\bar{u} - 1/2}{\sqrt{1/(12M)}},$$

并用标准正态分布的双侧 p 值判断均值是否显著偏离 0.5。本文取 $M = 20000$ ，并同时绘制运行均值随样本数变化的曲线。

计算流程如下：

```
for each generator:
    generate M one-dimensional samples
    compute final sample mean
    compute z-score under the independent uniform reference model
    compute two-sided p-value
    record the running mean curve
```

compare whether the final mean is close to 0.5

2.3 问题答案

生成器	最终样本均值	$\bar{u} - 0.5$	z 值	双侧 p 值
numpy_pcg64	0.5012593264	0.0012593264	0.616941	0.537273
lcg_minstd	0.5026607291	0.0026607291	1.303486	0.192409
lcg_slide_large_m	0.5268434426	0.0268434426	13.150547	1.68947E-39
lcg_slide_small	0.5019008299	0.0019008299	0.931213	0.351744

生成器	最终样本均值	$\bar{u} - 0.5$	z 值	双侧 p 值
lcg_bad27	0.5925925926	0.0925925926	45.360921	0
lcg_bad9	0.4444500000	-0.0555500000	-27.213831	4.4558E-163




图 3: 运行样本均值检验

从表 2 可见, `numpy_pcg64` 和 `lcg_minstd` 的样本均值没有显著偏离 0.5。`lcg_slide_large_m`、`lcg_bad27` 和 `lcg_bad9` 明显失败。`lcg_slide_small` 的均值检验没有失败, 但它已经在 Problem 1 的三维卡方检验中显著失败。

2.4 分析

样本均值检验是一个非常弱的必要条件。一个生成器可以具有接近 0.5 的均值, 却仍然存在严重周期结构、相邻样本相关性或高维格点缺陷。`lcg_slide_small` 正是这种情形: 它的均值看似正常, 但三维分箱中大量空箱, 说明其分布结构远远不合格。因此, 样本均值检验只能作为最初级的筛查, 而不能作为随机数质量的充分证明。

3 Problem 3: 自写准随机数生成器并检验

3.1 待求问题

编写自己的准随机数生成器, 并对其进行卡方随机性检验和样本均值的最小统计检验; 同时与系统自带随机数生成器做对比, 观察两者在“随机性”和“均匀覆盖性”上的差别。

3.2 解决方式

本文使用 Halton 低差异序列。对基数 b ，将正整数 n 写成

$$n = d_0 + d_1 b + d_2 b^2 + \dots,$$

则 radical inverse 定义为

$$\phi_b(n) = \frac{d_0}{b} + \frac{d_1}{b^2} + \frac{d_2}{b^3} + \dots.$$

三维准随机点取

$$(\phi_2(n), \phi_3(n), \phi_5(n)), \quad n = 1, 2, \dots$$

样本均值检验使用一维基数 2 的 Halton 序列。为了看清准随机数与普通伪随机数的差异，本文在同样的样本量下，用系统自带的 `numpy_pcg64` 作为对照组，分别比较：

1. 三维分箱卡方统计量；
2. 运行样本均值是否靠近 0.5。

由于准随机序列的目标不是产生独立随机样本，而是尽可能均匀地覆盖区域，所以其卡方统计量的解释不同于伪随机数。过大的卡方值说明分布不均；过小的卡方值则说明序列比随机样本更均匀。

对应生成流程如下：

```
for n = 1, 2, ..., sample_count:
    compute radical inverse in base 2
    compute radical inverse in base 3
    compute radical inverse in base 5
    form the 3D Halton point

use the 3D points for chi-square bin counts
use the base-2 sequence for the sample-mean test
```

3.3 问题答案

三维检验统一取 10000 个点、125 个箱子，单箱期望为 80；样本均值检验统一取 20000 个样本。实验结果如下。

检验	生成器	样本数	统计量	自由度或 z 值	p 值	辅助结果
三维卡方	numpy_pcg64	10000	97.5500000000	124	右尾 p=0.96191385301 中心 p=0.07617228826	箱频数 58 / 85
三维卡方	halton_2_3_5	10000	4.6750000000	124	右尾 p=1, 中心 p=4.64494821E-64	箱频数 76 / 85
样本均值	numpy_pcg64	20000	0.5012593264	0.6169414369	0.5372733541	运行均值区间 0.1698609510 / 0.5117193556
样本均值	halton_base2	20000	0.4999153702	-0.0414599761	0.9669291999	运行均值区间 0.375 / 0.5




图 4: 系统内置随机数与 Halton 的三维分箱频数对比

3.4 分析

与系统自带的 `numpy_pcg64` 相比, Halton 序列的差异非常明显。`numpy_pcg64` 的三维卡方值为 97.55, 落在普通随机波动的合理范围内; 而 Halton 的卡方值只有 4.675, 箱频数只在 76 到 85 之间变化, 说明它把点分布得比独立随机样本还要均匀得多。这会导致右尾 p 值接近 1、中心 p 值极小。

两者在样本均值检验上都接近 0.5, 因此如果只看均值, 几乎都会被判为“正常”; 真正把它们区分开的, 是




图 5: 系统内置随机数与 Halton 的运行样本均值对比

三维分箱后的空间结构。也就是说，准随机序列并不是“更随机”，而是“更均匀”。这种性质适合数值积分和面积估计，但不适合需要不可预测性的模拟或加密场景。

II. 接受-拒绝法估计圆周率

4 Problem 4(a): 使用伪随机数生成器估计 π

4.1 待求问题

用传统接受-拒绝法计算 π ，其中面积关系为

$$\frac{A_{\text{circle}}}{A_{\text{square}}} = \frac{\pi}{4}.$$

本小问要求使用自己写的伪随机数生成器。

4.2 解决方式

在单位正方形 $[0, 1]^2$ 中生成点 (x_i, y_i) 。若

$$x_i^2 + y_i^2 \leq 1,$$

则该点落在四分之一单位圆内。设 N 个点中有 M 个落在圆内，则

$$\hat{\pi} = 4 \frac{M}{N}.$$

伪随机数生成器使用 Park-Miller 型 LCG:

$$m = 2^{31} - 1, \quad a = 48271, \quad c = 0.$$

若 $M \sim \text{Binomial}(N, \pi/4)$, 则

$$\text{sd}(\hat{\pi}) \approx 4\sqrt{\frac{(\pi/4)(1 - \pi/4)}{N}},$$

误差典型量级为 $O(N^{-1/2})$ 。

4.3 问题答案

伪随机 LCG 的估计结果如下。

N	$\hat{\pi}_{\text{pseudo}}$	绝对误差
100	3.4000000000	0.2584073464
500	3.1920000000	0.0504073464
1000	3.2200000000	0.0784073464
5000	3.1712000000	0.0296073464
10000	3.1620000000	0.0204073464
50000	3.1510400000	0.0094473464
100000	3.1396800000	0.0019126536
500000	3.1399840000	0.0016086536
1000000	3.1393840000	0.0022086536

当 $N = 1000000$ 时, 伪随机 LCG 得到

$$\hat{\pi}_{\text{pseudo}} = 3.1393840000,$$

绝对误差为

$$2.2086536 \times 10^{-3}.$$

4.4 分析

伪随机接受-拒绝法的主要误差来自 Monte Carlo 抽样波动, 典型量级为 $O(N^{-1/2})$ 。因此增加样本量可以降低误差, 但收敛速度较慢; 即使 N 增大, 单次实验的误差也会有随机起伏, 不必严格单调下降。

5 Problem 4(b): 使用准随机数生成器估计 π 并比较

5.1 待求问题

使用自己的准随机数生成器重复接受-拒绝法计算 π ，并评论伪随机方法与准随机方法哪一种得到更好的结果，尽量给出更多原因。

5.2 解决方式

准随机数生成器使用二维 Halton 序列，基数为 $(2, 3)$ 。与伪随机方法相同，仍在单位正方形内生成点，并用

$$\hat{\pi} = 4 \frac{M}{N}$$

估计圆周率。准随机样本不再满足独立二项模型，因此不能直接套用伪随机方法的二项标准差；其优势来自低差异点集对单位正方形的更均匀覆盖。

比较流程如下：

```
for each sample size N:
    estimate pi using pseudo-random LCG points
    estimate pi using 2D Halton points
    compute absolute errors against true pi

compare error size and point coverage patterns
```

5.3 问题答案

两种方法的比较结果如下。

N	伪随机 LCG $\hat{\pi}$	伪随机绝对误差	Halton $\hat{\pi}$	Halton 绝对误差
100	3.4000000000	0.2584073464	3.2400000000	0.0984073464
500	3.1920000000	0.0504073464	3.1760000000	0.0344073464
1000	3.2200000000	0.0784073464	3.1480000000	0.0064073464
5000	3.1712000000	0.0296073464	3.1472000000	0.0056073464
10000	3.1620000000	0.0204073464	3.1448000000	0.0032073464
50000	3.1510400000	0.0094473464	3.1423200000	0.0007273464
100000	3.1396800000	0.0019126536	3.1420800000	0.0004873464
500000	3.1399840000	0.0016086536	3.1416240000	0.0000313464
1000000	3.1393840000	0.0022086536	3.1415720000	0.0000206536

当 $N = 1000000$ 时，Halton 准随机序列得到

$$\hat{\pi}_{\text{quasi}} = 3.1415720000,$$




图 6: 接受-拒绝法估计圆周率的误差收敛




图 7: 伪随机与准随机前 2000 个点的覆盖差异

绝对误差为

$$2.06536 \times 10^{-5}.$$

本次实验中，准随机方法明显优于伪随机方法。

5.4 分析

准随机方法表现更好的主要原因是点集覆盖更均匀。普通伪随机点即使总体服从均匀分布，也会自然产生局部聚集和空洞；面积估计的误差因此受到随机波动支配，典型量级为 $O(N^{-1/2})$ 。Halton 序列通过低差异构造减少局部空洞，使圆弧边界附近的误差更接近确定性覆盖误差，因此在二维面积估计中常能得到更小误差。

不过，这一结论并不意味着准随机序列在所有问题中都优于伪随机序列。若问题维度很高、被积函数不光滑，或需要真实随机性和独立误差估计，则准随机序列的优势可能减弱，甚至需要随机化低差异序列才能给出可靠的不确定度估计。本题是二维面积估计，正好适合低差异序列发挥优势。