


Homework 12

Monte Carlo 积分、方差缩减与高维体积估计

姜玥晟

2026-05-27



项目	内容
作业编号	HW12
作业目录	HW/11
学生姓名	姜玥晟
报告主题	Monte Carlo 积分、重要性抽样、分层抽样、准随机序列、hit-and-miss 与高维球体积
实验环境	Python 3.13.5、numpy 2.3.3、scipy 1.16.2、matplotlib 3.10.7、py pandoc
报告说明	正文按小问逐节组织；每个小问内部自成完整结构。

I. 传统 Monte Carlo 积分

Problem 1(a): 复现 MC 估计量分布

待求问题

使用传统 Monte Carlo 方法计算

$$I = \int_0^1 e^x dx.$$

复现题图中 MC 积分估计量的分布图，样本数 N 至少取 1000，样本越多越好。

解决方式

令 $U_i \sim U(0, 1)$ ，则传统 MC 估计量为

$$\hat{I}_N = \frac{1}{N} \sum_{i=1}^N e^{U_i}.$$

积分精确值为

$$I = e - 1 = 1.718281828459045.$$

单个样本 $Y = e^U$ 的方差为

$$\text{Var}(Y) = \int_0^1 e^{2x} dx - (e - 1)^2 = \frac{e^2 - 1}{2} - (e - 1)^2.$$

因此重复实验得到的 $\hat{I}_N$ 应近似服从中心在 $e - 1$ 、标准差为 $\sqrt{\text{Var}(Y)/N}$ 的正态分布。为了观察采样点数增加时的收缩现象，本文分别取

$$N = 1000, \quad 10000, \quad 100000, \quad 1000000, \quad 10000000.$$

对每个 N 重复做多次独立积分估计，绘制估计量分布。第一张图使用固定 bin 宽 0.001 展示整体形状；第二张图在 $e - 1$ 附近放大，使用固定 bin 宽 0.0001 展示高采样数时的尖峰结构。若 $N \rightarrow \infty$ ，则 $\hat{I}_N$ 依概率收敛到 $e - 1$ ，分布弱收敛到位于 $e - 1$ 的 Dirac delta。

问题答案

重复实验结果如下。

每次估计样本数 N	独立积分估计次数	估计均值	经验标准差	理论标准差	精确值	均值绝对误差
1000	100000	1.718264	0.015531	0.015557	1.718282	1.74×10^{-5}
10000	10000	1.718315	0.004966	0.004920	1.718282	3.34×10^{-5}
100000	10000	1.718252	0.001542	0.001556	1.718282	2.95×10^{-5}
1000000	1000	1.718267	0.000496	0.000492	1.718282	1.44×10^{-5}
10000000	200	1.718290	0.000154	0.000156	1.718282	8.60×10^{-6}




图 1: 传统 MC 估计量分布

图中绿色、橙色、红色、紫色和蓝色曲线分别对应 $N = 1000, 10000, 100000, 1000000, 10000000$ 。随着每次积分使用的采样点数增加，估计量分布的宽度按 $N^{-1/2}$ 收缩，峰值不断升高并集中到 $e - 1$ 附近。黑色竖虚线表示极限位置，也就是 $N \rightarrow \infty$ 时的 Dirac delta 支撑点。局部放大图进一步显示：当 N 从 10^5 增大到 10^7 时，分布已经从可见的钟形曲线压缩为精确值附近很窄的尖峰。

理解

这个积分的被积函数光滑且方差有限，所以单次积分估计的标准误差遵循 $O(N^{-1/2})$ 。表中经验标准差从 1.553×10^{-2} 逐步降到 1.537×10^{-4} ，与理论标准差从 1.556×10^{-2} 降到 1.556×10^{-4} 的趋势一致。直观上， N 越大，估计量越不容易偏离精确积分，分布也就越接近集中在 $e - 1$ 的狄拉克函数。




图 2: 传统 MC 估计量分布的局部放大

Problem 1(b): 最终结果与误差估计

待求问题

给出该积分的最终 Monte Carlo 计算结果, 并估计误差。

解决方式

最终估计使用独立样本 $N = 1000000$ 。用样本标准差 s 估计标准误差:

$$\text{SE}(\hat{I}_N) = \frac{s}{\sqrt{N}}.$$

同时与精确值 $e - 1$ 比较, 得到绝对误差。

问题答案

最终结果为

$$\hat{I} = 1.71831573223, \quad \text{SE} = 4.919682842021678 \times 10^{-4}.$$

与精确值 1.718281828459045 相比, 绝对误差为

$$|\hat{I} - I| = 3.39037716857 \times 10^{-5}.$$

该误差约为 0.069 个标准误差，落在 MC 随机波动的正常范围内。

理解

标准误差给的是一次随机实验的典型波动尺度，不要求实际误差一定接近它。本次运行的实际误差远小于一个标准误差，说明这次随机样本比较“幸运”，但从方法评价上仍应使用标准误差作为可重复的误差量级。

II. 重要性抽样处理端点奇异性

Problem 2: 重要性抽样计算奇异积分

待求问题

使用重要性抽样计算

$$I = \int_0^1 \frac{dx}{\sqrt{x} + x}.$$

如果在 $[0, 1]$ 上均匀采样，估计量方差会因为端点 $x = 0$ 附近的近似对数发散而无穷大，误差下降慢于 $N^{-1/2}$ 。改从

$$g(x) = \alpha \frac{1}{\sqrt{x}}$$

型密度中采样，系数 α 自行决定，使 $f(x)/g(x)$ 具有有限方差。

解决方式

归一化条件给出

$$1 = \int_0^1 \alpha x^{-1/2} dx = 2\alpha, \quad \alpha = \frac{1}{2}.$$

因此

$$g(x) = \frac{1}{2\sqrt{x}}, \quad G(x) = \sqrt{x}.$$

若 $U \sim U(0, 1)$ ，则取

$$X = U^2$$

即可服从 $g(x)$ 。重要性抽样权重为

$$\frac{f(X)}{g(X)} = \frac{1}{\sqrt{X} + X} \cdot 2\sqrt{X} = \frac{2}{1 + \sqrt{X}}.$$

该权重在 $[1, 2]$ 内有界，所以估计量方差有限。

问题答案

解析值为

$$I = 2 \ln 2 = 1.3862943611198906.$$

取 $N = 1000000$ 个重要性样本，得到

方法	α	样本数	估计值	标准误差	绝对误差
$g(x) = 1/(2\sqrt{x})$	0.5	1000000	1.386278	2.798×10^{-4}	1.667×10^{-5}




图 3: 重要性抽样权重分布

理解

重要性抽样的核心不是单纯改变采样点，而是让采样密度主动匹配被积函数的困难区域。原函数在 $x = 0$ 附近像 $x^{-1/2}$ ，因此均匀采样会偶尔抽到极大的函数值，导致方差发散。选择 $g(x) \propto x^{-1/2}$ 后，这个奇异




图 4: 均匀简单 MC 与重要性抽样的误差收敛

因子被采样密度吸收，剩下的权重 $2/(1 + \sqrt{x})$ 平滑且有界。收敛图中，重要性抽样的 RMS 误差基本沿 $N^{-1/2}$ 参考线下降，而均匀简单 MC 起伏明显且整体误差更大。

III. 分层抽样与方差比较

Problem 3(a): 简单 MC

待求问题

对

$$I = \int_0^1 \frac{dx}{\sqrt{x} + x}$$

先使用简单 Monte Carlo 方法计算，作为分层抽样的比较基线。

解决方式

简单 MC 使用 $U_i \sim U(0, 1)$,

$$\hat{I} = \frac{1}{N} \sum_{i=1}^N \frac{1}{\sqrt{U_i} + U_i}.$$

为了与分层抽样公平比较，总样本数取

$$N = 5000 \times 10 = 50000.$$

实验重复 140 次，用重复估计量的标准差作为经验误差尺度。

问题答案

简单 MC 的重复实验结果为

方法	重复次数	平均估计值	重复标准差	平均绝对误差
简单均匀 MC	140	1.384607	1.787×10^{-2}	1.687×10^{-3}

理解

简单均匀 MC 的困难来自 $x = 0$ 附近。虽然奇异性可积，但 $f(x)^2$ 在 0 附近近似 $1/x$ ，二阶矩对数发散。因此样本均值仍能接近正确积分，但普通有限方差 CLT 的标准误差解释并不严格，实际误差下降也容易缓慢。

Problem 3(b): 固定样本数分层抽样

待求问题

令 $k = 5000$ ，每层样本数 $n_i = 10$ ，层概率 $p_i = 1/5000$ 。在第 i 层内生成样本

$$U_{ij} = \frac{i-1+U}{5000}, \quad i = 1, \dots, 5000, \quad j = 1, \dots, 10,$$

并计算估计量方差。

解决方式

将 $[0, 1]$ 均匀划分为 $k = 5000$ 个小区间，第 i 层为

$$\left[\frac{i-1}{k}, \frac{i}{k} \right].$$

每层独立采样 $n_i = 10$ 个点，估计量为

$$\hat{I}_{\text{strat}} = \sum_{i=1}^k p_i \bar{f}_i, \quad p_i = \frac{1}{k}.$$

在重复实验中直接统计 $\hat{I}_{\text{strat}}$ 的经验方差。

问题答案

固定分层抽样结果为

方法	重复次数	平均估计值	重复标准差	平均绝对误差
固定分层 $n_i = 10$	140	1.386955	1.331×10^{-2}	6.603×10^{-4}




图 5: 分层抽样方差比较

理解

固定分层比简单 MC 的重复标准差从约 0.01787 降到约 0.01331，方差约降到简单 MC 的一半左右。原因是分层保证每个区间都有样本，不会像均匀简单抽样那样在某些区间过密、某些区间空缺。即使每层只有 10 个样本，空间覆盖也已经有所改善，但端点奇异性仍然限制了固定分层的效果。

Problem 3(c): 正则化 Neyman 分层分配

待求问题

在 $k = 5000$, $p_i = 1/5000$ 的条件下，求更合理的 n_i 分配及对应方差，并测试该分配是否真正优于固定分层。

解决方式

分层估计量的方差近似为

$$\text{Var}(\hat{I}) = \sum_{i=1}^k \frac{p_i^2 \sigma_i^2}{n_i},$$

其中 σ_i 是第 i 层内 $f(x)$ 的标准差。在总样本数固定为 $N = \sum_i n_i$ 时，Neyman 分配给出

$$n_i \propto p_i \sigma_i.$$

由于 p_i 相等，本题近似为 $n_i \propto \sigma_i$ 。但是第一层 $[0, 1/5000]$ 仍包含 $x = 0$ ，层内二阶矩发散，因此直接把它纳入 Neyman 分配并不严谨。为避免这个问题，本文先把第一层积分解析计算：

$$\int_a^b \frac{dx}{\sqrt{x} + x} = 2 \ln \frac{1 + \sqrt{b}}{1 + \sqrt{a}},$$

于是第一层贡献为

$$I_1 = 2 \ln \left(1 + \frac{1}{\sqrt{5000}} \right).$$

对剩余 4999 层，二阶矩有限。层内二阶矩可由

$$\int \frac{dx}{(\sqrt{x} + x)^2} = 2 \ln t - 2 \ln(1 + t) + \frac{2}{1 + t}, \quad t = \sqrt{x}$$

计算，再按 $n_i \propto \sigma_i$ 分配总样本数 50000。每个剩余层至少保留 1 个样本。

问题答案

正则化 Neyman 分配先解析处理第一层，第一层贡献为

$$I_1 = 0.02808613708918462.$$

剩余层的样本数范围为

$$\min_i n_i = 1, \quad \max_i n_i = 14758.$$

第 2 到第 11 层的样本分配为

$$[14758, 6627, 3964, 2708, 2000, 1555, 1253, 1038, 878, 755].$$

对应重复实验结果为

方法	重复次数	平均估计值	重复标准差	理论预测标准	
				差	平均绝对误差
正则化	140	1.386291	7.063×10^{-5}	7.387×10^{-5}	3.262×10^{-6}
Neyman 分层					

理解

正则化 Neyman 分层明显优于固定分层，重复标准差从 0.01331 降到 7.06×10^{-5} 。理论预测标准差为 7.39×10^{-5} ，与重复实验非常接近，说明分配策略本身是稳定的，不只是某一次随机结果“看起来不错”。

第一层解析处理很关键。若仍把第一层当普通层用少量 pilot 样本估计方差，分配会对极端样本非常敏感，结果显得粗糙且不可重复。把无限方差层单独拿掉后，剩余层的 Neyman 分配才有清楚的方差公式支撑。

Problem 3(d)：与重要性抽样的比较

待求问题

评论 Problem 3 的分层抽样结果和 Problem 2 的重要性抽样结果，解释它们之间的显著差异。

解决方式

比较三种方法的核心方差控制机制：

重要性抽样：改变采样密度，使权重有界；

分层抽样：固定空间覆盖，减少各区间抽样数波动；

正则化 Neyman 分层：解析处理无限方差层，再把更多样本分给高波动区间。

统一参考值为 $2 \ln 2$ 。

问题答案

在本次实验中， $N = 1000000$ 的重要性抽样标准误差约为 2.80×10^{-4} ，绝对误差约为 1.67×10^{-5} 。在总样本数 50000 的分层实验中，固定分层的重复标准差约为 1.33×10^{-2} ，正则化 Neyman 分层的重复标准差约为 7.06×10^{-5} 。

若只按样本量看，重要性抽样最自然地消除了奇异性；正则化 Neyman 分层在少得多的样本数下也能显著降低方差；普通固定分层则介于简单 MC 和正则化 Neyman 分层之间。

理解

重要性抽样和分层抽样都在处理同一个问题： $x = 0$ 附近对积分贡献和误差贡献都很大。重要性抽样直接把采样密度变成 $x^{-1/2}$ ，因此权重被压平；固定分层不改变每层内的函数形状，只保证每层都有样本。正则化 Neyman 分层则先把最麻烦的第一层解析掉，再把随机样本集中到高波动层，所以它比固定分层强很多。

IV. 伪随机与准随机简单 MC

Problem 4(a): 伪随机数生成器的收敛指数

待求问题

使用自写伪随机数生成器，用简单 MC 计算

$$I = \int_0^1 \frac{dx}{\sqrt{x+x}}.$$

拟合积分精度随随机数个数 N 的幂律关系，观察指数是否约为 $-1/2$ 。

解决方式

自写伪随机数生成器采用 Park-Miller 线性同余法：

$$x_{n+1} = 16807x_n \bmod (2^{31} - 1), \quad u_n = \frac{x_n}{2^{31} - 1}.$$

对多个 N 计算简单 MC 估计。为了降低单条随机路径偶然误差，伪随机结果使用 96 条不同种子的 RMS 绝对误差。拟合模型为

$$\log |\hat{I}_N - I| = a + b \log N,$$

其中 b 即收敛指数。

问题答案

拟合得到伪随机简单 MC 的误差指数为

$$b_{\text{pseudo}} = -0.420708811385.$$

最大样本数 $N = 262144$ 时，96 条种子的平均估计值和 RMS 误差为

$$\hat{I} = 1.38582301528, \quad \text{RMS error} = 0.00753322141799.$$

理解

指数没有精确达到 $-1/2$ ，而是略慢一些。图中的纵轴使用 fractional accuracy，即 $|\hat{I} - I|/I$ ，这与题面给出的参考图一致；淡色点表示实际采样误差，实线表示对数坐标下拟合出的幂律趋势。这与 Problem 2 中的分析一致：均匀简单 MC 面对 $x = 0$ 的 $x^{-1/2}$ 奇异性时，二阶矩存在对数发散，标准有限方差 CLT 的理想 $N^{-1/2}$ 标度会受到影响。因此本题中的伪随机简单 MC 只能表现为接近但慢于 $N^{-1/2}$ 的下降。




图 6: 伪随机与准随机收敛比较

Problem 4(b): 准随机数生成器的收敛指数

待求问题

使用自写准随机数生成器，用简单 MC 计算同一积分。拟合精度随样本数 N 的幂律指数，观察是否得到 $-2/3$ 、 -1 或其他值，并解释原因。

解决方式

准随机序列使用一维 Halton 序列。对基数 $b = 2$ ，若

$$n = d_0 + d_1 b + d_2 b^2 + \cdots,$$

则 radical inverse 为

$$\phi_b(n) = \frac{d_0}{b} + \frac{d_1}{b^2} + \frac{d_2}{b^3} + \cdots.$$

取 $u_n = \phi_2(n)$ ，代入同一个简单 MC 平均值，并使用与伪随机相同的对数拟合。

问题答案

拟合得到 Halton 准随机简单 MC 的误差指数为

$$b_{\text{quasi}} = -0.553230244088.$$

在 $N = 262144$ 时,

$$\hat{I} = 1.38620138477, \quad |\hat{I} - I| = 9.29763459563 \times 10^{-5}.$$

该误差显著小于同样样本量下伪随机简单 MC 的 RMS 误差。

理解

准随机序列在一维区间上的覆盖更均匀, 所以整体误差明显小于伪随机样本。但本题函数在端点处不光滑, 经典光滑低差异积分中常见的近似 $O(N^{-1})$ 优势被削弱。单条 Halton 序列的误差点会有明显起伏, 这是误差抵消随 N 改变造成的; 因此图中用拟合实线呈现主趋势。本实验得到约 -0.553 , 比伪随机更好, 但没有达到理想光滑情形的 -1 。

Problem 4(c): 与分层抽样和重要性抽样的综合比较

待求问题

综合评论 Problem 2、Problem 3 与 Problem 4 的结果, 解释重要性抽样、分层抽样、伪随机简单 MC 与准随机简单 MC 的显著差异。

解决方式

统一从两个角度比较: 一是是否改变了奇异端点附近的采样密度, 二是是否提高了样本点对区间的覆盖均匀性。所有结果都与解析值

$$I = 2 \ln 2$$

比较。

问题答案

本次实验中, 重要性抽样通过 $x = u^2$ 使权重有界, 10^6 样本的绝对误差约为 1.67×10^{-5} 。正则化 Neyman 分层用 50000 个随机样本达到约 7.06×10^{-5} 的重复标准差, 并且理论预测标准差与重复实验一致。Halton 准随机简单 MC 在 262144 个点时绝对误差约为 9.30×10^{-5} , 明显优于伪随机简单 MC 的 RMS 误差约 7.53×10^{-3} 。

理解

四种方法的差异可以概括为: 普通伪随机简单 MC 最容易受端点奇异性拖累; 准随机数改善了覆盖均匀性, 但没有改变函数奇异性; 正则化分层抽样把无限方差首层从随机估计中移除, 并把样本集中到高波动层; 重要性抽样直接按奇异形状采样, 是对本积分最自然的方差缩减方式之一。

V. Hit-and-Miss 振荡积分

Problem 5: 平移后使用 hit-and-miss 方法

待求问题

使用 hit-and-miss 方法积分振荡函数

$$I = \int_0^{\pi} 2 \sin \left(2\sqrt{\pi^2 - x^2} \right) dx.$$

若被积函数会变号，可以自行加一个常数使其变为非负，再扣除该常数的积分贡献。

解决方式

被积函数

$$h(x) = 2 \sin \left(2\sqrt{\pi^2 - x^2} \right)$$

的取值范围在 $[-2, 2]$ 内。因此取常数

$$C = 2$$

使

$$q(x) = h(x) + 2 \in [0, 4].$$

在矩形 $[0, \pi] \times [0, 4]$ 内均匀取点，若 $y \leq q(x)$ 则记为命中。设命中比例为 $\hat{p}$ ，则

$$\int_0^{\pi} q(x) dx \approx 4\pi\hat{p}, \quad \hat{I} = 4\pi\hat{p} - 2\pi.$$

同时用高精度数值积分作为参考。

问题答案

高精度数值积分参考值为

$$I_{\text{ref}} = -2.0961315535562566.$$

使用 $N = 5000000$ 次 hit-and-miss 试验得到

$$\hat{I} = -2.09348948595, \quad |\hat{I} - I_{\text{ref}}| = 0.00264206760534.$$

由命中比例的二项方差估计，标准误差为

$$SE = 0.00264936669325.$$

最终命中比例为

$$\hat{p} = 0.3334054.$$




图 7: hit-and-miss 采样点、平移函数与运行估计




图 8: hit-and-miss 积分收敛

理解

hit-and-miss 方法把一维积分转化成二维面积估计，直观但方差通常比直接平均函数值更大。这里加 $C = 2$ 后函数非负，矩形高度为 4，左图中的蓝点表示命中区域，红点表示拒绝区域；右图显示估计量随样本数逐步靠近参考值。题图中示例值约为 -2.1095 ，本次高精度数值积分给出更稳定的参考值 -2.09613 ；500 万次随机试验的实际误差小于一个标准误差，说明结果与参考值在随机误差范围内一致。

VI. 高维球体积的 Monte Carlo 估计

Problem 6: 20 维及更高维单位球体积

待求问题

实现 Monte Carlo 方法，估计任意维数 N 和半径 R 的球体积

$$V(N, R) = \int_{x_1^2 + x_2^2 + \dots + x_N^2 \leq R^2} dx_1 dx_2 \dots dx_N.$$

计算 $R = 1$, $N = 20$ 的球体积，并尝试 25 维或更高维，同时与传统方法比较。

解决方式

传统接受-拒绝法在超立方体 $[-R, R]^d$ 中均匀采样，若

$$\sum_{i=1}^d x_i^2 \leq R^2$$

则命中。估计量为

$$\hat{V}_{\text{cube}} = (2R)^d \frac{M}{N_{\text{sample}}}.$$

解析公式为

$$V_d(R) = \frac{\pi^{d/2} R^d}{\Gamma(d/2 + 1)}.$$

为了说明传统超立方体法在高维下退化，还使用径向积分作对照：

$$V_d(1) = S_{d-1} \int_0^1 r^{d-1} dr, \quad S_{d-1} = \frac{2\pi^{d/2}}{\Gamma(d/2)}.$$

该对照仍用 Monte Carlo 平均计算一维径向积分，但避免了高维超立方体中的极低命中率。

问题答案

关键维数结果如下。

传统超立方体 hit-or-miss 的结果如下。表中的“期望命中数”由精确体积除以超立方体体积后乘以样本数得到，用来判断零命中是否合理。

维数	精确体积	样本数	期望命中数	实际命中数	估计值	理论相对标准误差
10	2.550164	500000	1245.197	1260	2.58048	0.028303
15	0.3814433	700000	8.149	11	0.5149257	0.350315
20	0.02580689	1000000	0.02461	0	0	6.374294
25	0.0009577224	1000000	0.00002854	0	0	187.178137
30	0.00002191535	1000000	0.0000000204	0	0	6999.639855

径向 Monte Carlo 对照结果如下。

维数	精确体积	径向 MC 估计	相对标准误差	相对误差
10	2.550164	2.567562	0.003788	0.006822
15	0.3814433	0.3824331	0.004752	0.002595
20	0.02580689	0.02564242	0.005528	0.006373
25	0.0009577224	0.0009607087	0.006276	0.003118
30	0.00002191535	0.00002185444	0.006881	0.002780




图 9: 高维单位球体积估计与命中率退化

因此， $R = 1$, $N = 20$ 的解析体积为

$$V_{20}(1) = 0.02580689139.$$

图中左侧的倒三角标记表示传统超立方体法在该维数下零命中，不能在对数轴上直接画出 0。传统超立方体 hit-or-miss 在 10^6 个点下零命中，给出 0；这并不是程序没有工作，而是因为期望命中数只有 0.02461，零命中概率约为 $\exp(-0.02461) \approx 0.976$ 。径向 MC 对照给出

$$\hat{V}_{20} = 0.0256424202394,$$

相对误差约为 0.00637，相对标准误差约为 0.00553。

25 维时解析值为

$$V_{25}(1) = 0.000957722408823,$$

传统方法同样零命中，而且期望命中数仅为 2.85×10^{-5} ；径向 MC 给出 0.000960708676158，相对误差约为 0.00312，仍在其相对标准误差 0.00628 的同一量级内。

理解

高维球体积估计展示了典型的维数灾难。虽然传统超立方体接受-拒绝法概念最直接，但单位球在 $[-1, 1]^d$ 中的体积比例随维数快速下降。到 20 维时，100 万个点的期望命中数远小于 1，零命中反而是大概率事件。径向积分把问题化为一维平均，利用了球的对称性，因此仍能稳定复现解析公式。这说明高维 Monte Carlo 不能只靠“多撒点”，更需要使用问题结构设计采样方式。